โจทย์โครงงาน ML: ทำนายชั่วโมงการนอนหลับคืนถัดไปจากข้อมูล Wearable (Mixed Sleep: LifeSnaps + GLOBEM)

ที่มาและความสำคัญของปัญหา

การนอนหลับที่เพียงพอเป็นปัจจัยสำคัญต่อสุขภาพกายและใจ ผลการเรียน และสมาธิในการทำงาน ปัจจุบันนาฬิกาอัจฉริยะ (wearable) อย่าง Fitbit บันทึกจำนวนก้าวและการนอนของผู้ใช้ได้ทุกวันโดยไม่รบกวนชีวิตประจำวัน หากสามารถ ทำนายล่วงหน้าตั้งแต่ช่วงเย็น ได้ว่าคืนนี้ผู้ใช้จะนอนได้กี่ชั่วโมง แอปพลิเคชันก็จะส่งคำแนะนำหรือแจ้งเตือนได้ทันเวลา ก่อนที่ปัญหาจะเกิดขึ้น

1. หากนอนน้อยเกินไป (น้อยกว่า 6 ชั่วโมง) ต่อเนื่อง ส่งผลต่อสมาธิ อารมณ์ และผลการเรียน และการนอนน้อยมักเกิดซ้ำ หลังคืนที่นอนน้อย โอกาสที่คืนถัดไปจะนอนน้อยอีกสูงถึงประมาณ 35% เทียบกับประมาณ 17% หลังคืนปกติ

2. หากนอนนานผิดปกติ อาจสะท้อนการ "นอนชดเชย" หลังอดนอน หรือรูปแบบชีวิตที่เปลี่ยนไป เช่น ช่วงล็อกดาวน์ COVID-19

วิธีง่ายที่สุดคือใช้ค่าเฉลี่ยการนอน 7 วันที่ผ่านมาเป็นคำทำนาย อย่างไรก็ตามการทำนายการนอนยังมีความท้าทายหลายประการ เช่น

- ความแปรปรวนของการนอน ภายในคนเดียวกันในแต่ละคืน (SD ≈ 1.39 ชม.) มากกว่า ความแตกต่างระหว่างบุคคล (SD ≈ 0.79 ชม.) ทำให้แม้รู้จักผู้ใช้ดีแล้วก็ยังทำนายได้ไม่สมบูรณ์
- ข้อมูลมาจากอุปกรณ์และประชากรต่างกัน LifeSnaps บันทึกเวลาตื่นกลางดึกประมาณ 58 นาที/คืน เทียบกับประมาณ 26 นาทีของ GLOBEM และนอนน้อยกว่าประมาณ 30 นาที (domain shift)
- พฤติกรรมเปลี่ยนตามสถานการณ์ เช่น ช่วงล็อกดาวน์ปี 2020 จำนวนก้าวลดจากประมาณ 10,900 เหลือ 4,600 ก้าว/วัน และเวลานอนเฉลี่ยเพิ่มจาก 7.1 เป็น 7.4 ชั่วโมง
- ข้อมูลหายบ่อย เพราะผู้ใช้ไม่ได้สวมนาฬิกา หรือคืนนั้นบันทึกได้ไม่สมบูรณ์

ด้วยเหตุนี้จึงเกิดแนวคิดในการพัฒนา โมเดล Machine Learning ที่นำข้อมูลหลายประเภทมาวิเคราะห์ร่วมกัน ได้แก่ ประวัติการนอนย้อนหลัง กิจกรรมระหว่างวัน วันในสัปดาห์ และแหล่งข้อมูล เพื่อให้โมเดลเรียนรู้ความสัมพันธ์ที่ซับซ้อนและทำนายได้ดีกว่าค่าเฉลี่ยย้อนหลังแบบง่าย ให้นักศึกษาพัฒนาโมเดล ML/DL ทำนาย จำนวนชั่วโมงการนอนหลับของคืนถัดไป (sleep_hours_next) จากข้อมูล Fitbit ของผู้เข้าร่วม 733 คน (41,733 วัน) ในชุดข้อมูล Mixed Sleep

เมื่อจบโครงงาน นักศึกษาควรทำได้ดังนี้

1. เตรียมข้อมูล time series รายวันจาก wearable ที่มีค่าหาย และรวมข้อมูลจาก 2 แหล่งที่มีการกระจายต่างกัน
2. สร้าง features จากประวัติย้อนหลัง (lag, rolling mean, ค่าเทียบกับค่าปกติของแต่ละคน) โดยไม่ใช้ข้อมูลจากอนาคต
3. ออกแบบการแบ่งข้อมูลที่ไม่รั่วไหล (no data leakage) โดยแบ่งตามบุคคล และใช้ grouped cross-validation
4. สร้างโมเดล regression และเปรียบเทียบกับ baseline
5. ประเมินผลแยกตามแหล่งข้อมูล ประเมินคลาสที่ไม่สมดุล และอธิบายว่า feature ใดสำคัญที่สุด

รูปแบบงาน: กลุ่มละ 2 คน

ชุดข้อมูล

ไฟล์ data/processed/mixed_sleep_tasks.csv ขนาด 41,733 แถว × 21 คอลัมน์ ครอบคลุม 733 คน ใช้เพียง pandas, numpy และ scikit-learn ข้อมูลมาจาก 2 การศึกษาที่ใช้ Fitbit นำมาต่อกันด้วย features ที่มีร่วมกัน

แหล่งข้อมูล	กลุ่มตัวอย่าง	ช่วงเวลา	จำนวนคน	จำนวนคืน
GLOBEM INS-W_1	นักศึกษามหาวิทยาลัย (US)	เม.ย.–ก.ค. 2018	137	7,276
GLOBEM INS-W_2	นักศึกษามหาวิทยาลัย (US)	มี.ค.–มิ.ย. 2019	210	10,850
GLOBEM INS-W_3	นักศึกษามหาวิทยาลัย (US)	มี.ค.–มิ.ย. **2020** (ล็อกดาวน์)	131	7,907
GLOBEM INS-W_4	นักศึกษามหาวิทยาลัย (US)	มี.ค.–ก.ค. 2021	190	12,259
LifeSnaps	ผู้ใหญ่ในยุโรป (Fitbit Sense)	พ.ค. 2021–ม.ค. 2022	65	3,441

หน่วยข้อมูล: 1 แถว = ผู้เข้าร่วม 1 คน ในวันที่ t features คือสิ่งที่รู้ได้ภายในเย็นวันที่ t ส่วน target คือการนอนของคืนที่เริ่มในเย็นวันนั้น

Data preprocessing

- ค่าว่าง (NaN) หมายถึงไม่ได้สวมนาฬิกา หรือคืนนั้นไม่ถูกต้อง (เวลาบนเตียงน้อยกว่า 3 ชม. หรือหลับเกิน 15 ชม.) ห้าม impute target เด็ดขาด
- GLOBEM มีสัดส่วนประมาณ 92% ของแถว ค่า MAE รวมจึงถูก GLOBEM ครอบงำ ต้องรายงานแยกแหล่งด้วยเสมอ
- LifeSnaps บันทึกเวลาตื่นกลางดึกประมาณ 58 นาที/คืน (GLOBEM ประมาณ 26 นาที) และนอนน้อยกว่าประมาณ 30 นาที ควรพิจารณา standardise แยกตามแหล่ง หรือใช้ is_globem
- คืนวันศุกร์และวันเสาร์นอนนานกว่าคืนอื่นประมาณ 0.4 ชม. (≈ 7.45 ชม. เทียบกับ ≈ 7.05 ชม.)
- คอลัมน์ lastnight_minutesToFallAsleep มีค่าเกือบทั้งหมดเป็น 0 ใน Fitbit ตัดทิ้งได้
- ตรวจสอบแล้วว่าในวันติดกัน sleep_hours_next[t] × 60 == lastnight_minutesAsleep[t+1] ทุกแถว ดังนั้น **ห้ามสร้าง feature จากวันที่ t+1 เป็นต้นไป**

การตีความหมายของชั่วโมงการนอน (target labels)

sleep_hours_next	ความหมาย
< 6 ชม.	นอนน้อย (short sleep)
6–9 ชม.	ระดับปกติ
> 9 ชม.	นอนนาน (long sleep)

ขอบเขตและข้อกำหนดบังคับ

1. **Target: ทำนายค่า sleep_hours_next (regression) งานเดียว**

- แปลงค่าที่ทำนายเป็น 3 คลาส (< 6, 6–9, > 9) เพื่อรายงาน Confusion matrix และ F1

2. **ชุดข้อมูล:**

- ใช้คอลัมน์ split ตามที่กำหนด (แบ่งตามบุคคลแล้ว) ห้ามแบ่งใหม่ตามแถว
- ปรับ hyperparameter ด้วย 5-fold grouped CV จากคอลัมน์ cv_fold บนชุด train เท่านั้น
- ใช้ test set ครั้งเดียว ตอนท้ายสุด

3. **หน่วยข้อมูล: 1 แถว = 1 คน × 1 วัน**

- Label = sleep_hours_next ของคืนที่เริ่มเย็นวันที่ t
- Feature ใด ๆ ต้องคำนวณจากข้อมูลของคนเดียวกันในวันที่ ≤ t เท่านั้น (lag / rolling ต้องเรียงตาม date ภายใน participant_id)

4. **การคัดกรอง (3 กฎ)**

- ตัดแถวที่ sleep_hours_next เป็นค่าว่าง
- ตัดแถวที่ไม่มีประวัติการนอนเลย (lastnight_minutesAsleep และ mean7d_minutesAsleep เป็นค่าว่างทั้งคู่)
- ตัดแถวที่ steps เป็นค่าว่างหรือเท่ากับ 0 (ไม่ได้สวมนาฬิการะหว่างวัน)
- รายงานจำนวนแถวที่เหลือหลังแต่ละกฎ แยก train / test และแยก GLOBEM / LifeSnaps

Features

- ประวัติย้อนหลังของการนอน กิจกรรม (steps) วันในสัปดาห์ แหล่งข้อมูล ค่าเทียบกับค่าปกติของแต่ละคน หรือข้อมูลอื่นที่คุณสร้างเอง
- ห้ามใช้เป็น feature: sleep_efficiency_next, participant_id, split, cv_fold และข้อมูลจากวันที่ t+1 เป็นต้นไป

Target:

- sleep_hours_next (หน่วย ชั่วโมง)

ตัวชี้วัด (คำนวณบน test set)

- MAE (หน่วย ชั่วโมง) ตัวชี้วัดหลัก รายงานทั้งแบบรวม และแยก GLOBEM / LifeSnaps
- RMSE
- R^2 score และ Pearson r
- confusion matrix และ macro F1 ของ 3 คลาส จากค่าที่ทำนายแปลงเป็นคลาส
- metric เสริม (ไม่บังคับ): เพิ่มได้ 1 ตัวที่กลุ่มเห็นว่าเหมาะกับปัญหานี้ (เช่น worst-group MAE ตาม cohort หรือ recall ของคลาสนอนน้อย) พร้อมอธิบายเหตุผลในรายงาน

โมเดลที่ต้องเปรียบเทียบ (4 โมเดล)

- M0 (บังคับ): Baseline ค่าเฉลี่ย 7 วัน (mean7d_minutesAsleep / 60) ทุกกลุ่มต้องใช้เหมือนกัน เพื่อให้เปรียบเทียบผลข้ามกลุ่มได้
- M1–M3 (เลือกเอง): โมเดล ML/DL ใดก็ได้ 3 โมเดลที่แตกต่างกัน ต้องอธิบายในรายงานว่าเลือกโมเดลนั้นเพราะอะไร และเหมาะกับลักษณะข้อมูลชุดนี้อย่างไร

ผลที่ต้องส่ง

- ไฟล์ results.csv ตามรูปแบบนี้ (เปรียบเทียบ 4 โมเดล; MODEL_DESC = ชื่อโมเดลที่เลือก, N_TEST = จำนวนแถวใน test set)

MODEL	MODEL_DESC	MAE	RMSE	R2	PEARSON_R	MACRO_F1	MAE_GLOBEM	MAE_LIFESNAPS	N_TEST
M0	Baseline mean7d								
M1									
M2									
M3									

- **ค่าอ้างอิง** (test MAE ของโมเดลตัวอย่างในคู่มือข้อมูล): GLOBEM ≈ 1.14 ชม., LifeSnaps ≈ 0.94 ชม. เมื่อเทรนรวมทั้งสองแหล่ง ใช้ตรวจสอบความสมเหตุสมผลของผลเท่านั้น
- **กราฟที่ต้องส่ง 1 รูป**

ชั่วโมงการนอนจริงเทียบกับค่าที่แต่ละโมเดลทำนาย ตลอดช่วงเวลาของผู้เข้าร่วม 1 คนในชุด test (แกน x = วันที่, แกน y = ชั่วโมง) พร้อมเส้นแบ่ง 6 และ 9 ชม.

สิ่งที่ต้องส่งและงานโบนัส

☐ Notebook เดียวที่รันได้ตั้งแต่ต้นจนจบ (Restart & Run All) กำหนด random_state=42

☐ features_example.csv: 10 แถวตัวอย่าง (participant_id + date ที่ผู้สอนกำหนด) เทียบกับค่าเฉลย

☐ results.csv ครบ 4 แถว

☐ กราฟการนอน 1 รูป

☐ รายงานไม่เกิน 5 หน้า ตอบ 4 คำถาม:

หลังคัดกรองเหลือกี่แถว แต่ละกฎตัดออกไปเท่าไร

เลือก M1–M3 เป็นโมเดลอะไร เพราะอะไร โมเดลไหนดีที่สุด ดีกว่า M0 กี่ % ทั้งแบบรวมและแยก GLOBEM / LifeSnaps

Feature 3 อันดับแรกคืออะไร สอดคล้องกับความรู้เรื่องการนอน (เช่น การนอนชดเชย ผลของวันหยุด ผลของกิจกรรม) อย่างไร

โมเดลพลาดมากที่สุดในกรณีไหน (วันในสัปดาห์ / กลุ่ม cohort / ผู้เข้าร่วมแบบใด) เพราะอะไร

☐ นำเสนอ 10 นาที + ถามตอบ 5 นาที

งานโบนัส (เลือก 1 หัวข้อ)

- Transfer learning: ประเมินเฉพาะ LifeSnaps เทียบการเทรนด้วย LifeSnaps อย่างเดียว กับการรวม GLOBEM (naive pooling, is_globem, sample weighting) แล้วตอบว่า 1 คืนของ LifeSnaps มีค่าเท่ากับกี่คืนของ GLOBEM
- Distribution shift: เทรนด้วย INS-W_1 + INS-W_2 แล้วทดสอบแยก INS-W_3 (ล็อกดาวน์), INS-W_4 และ LifeSnaps วิเคราะห์ว่า feature ใดเปลี่ยนไป และเสนอวิธีลดช่องว่าง
- Personalisation: ใช้ k คืนแรกของผู้เข้าร่วม test (k = 0, 3, 7, 14) ปรับโมเดลให้เป็นรายบุคคล (เช่น shrinkage bias × k / (k + λ)) และพล็อต MAE เทียบกับ k

- Uncertainty: ใช้ quantile regression หรือ conformal prediction ให้ช่วงทำนาย 80% เช่น "คืนนี้จะนอน 6.2–7.8 ชม."
-

เกณฑ์การให้คะแนน

คะแนนเต็ม 100

หมวด	เกณฑ์ตรวจ	คะแนน
เตรียมข้อมูล	ใช้ split / cv_fold ตามที่กำหนด ไม่มีผู้เข้าร่วมซ้ำระหว่าง train และ test	5
เตรียมข้อมูล	label = sleep_hours_next ไม่ impute target และใช้ครบ 3 กฎการคัดกรอง	10
เตรียมข้อมูล	รายงานจำนวนแถวหลังแต่ละกฎ	5
Features	features ของแถวตัวอย่างตรงกับเฉลย และไม่ใช้ข้อมูลจากอนาคต	25
โมเดล	รันครบทุกโมเดล และปรับ hyperparameter ด้วย grouped CV	10
โมเดล	อธิบายเหตุผลการเลือกโมเดล M1–M3 (และ metric เสริม ถ้ามี) ได้สอดคล้องกับลักษณะข้อมูล	5
ผลลัพธ์	results.csv ครบ	10
ผลลัพธ์	MAE, RMSE, R^2 ของแต่ละโมเดล (รวม + แยกแหล่ง) และ Confusion matrix	10
ผลลัพธ์	กราฟ 1 รูป มีชื่อแกนและหน่วย	5
รายงาน	ตอบครบ 4 คำถาม ทุกคำตอบอ้างตัวเลขจากผลของตัวเอง	15
รวม		**100**

ข้อควรระวัง

- สิทธิ์การใช้ข้อมูล: ห้ามอัปโหลดขึ้น public repository, Kaggle, shared drive หรือเครื่องมือแชตใด ๆ และห้ามพยายามระบุตัวตนผู้เข้าร่วม
- ข้อมูลการนอนเป็นค่าประมาณจาก Fitbit ไม่ใช่ผลตรวจการนอน (polysomnography)
- LifeSnaps มีเพียง 65 คน ค่า MAE แยกแหล่งของ LifeSnaps จึงแกว่งได้มาก ควรรายงานคู่กับผล CV
- ผลเป็นงานเพื่อการเรียนรู้เท่านั้น ไม่ใช่การวินิจฉัยหรือคำแนะนำทางการแพทย์

แหล่งอ้างอิงชุดข้อมูล

- Yfantidou, S. et al. LifeSnaps, a 4-month multi-modal dataset capturing unobtrusive snapshots of our lives in the wild. Scientific Data 9, 663 (2022).
- Xu, X. et al. GLOBEM Dataset: Multi-Year Datasets for Longitudinal Human Behavior Modeling Generalization. NeurIPS 2022 Datasets and Benchmarks Track.